

الجمهورية الجزائرية الديمقراطية الشعبية

ⵜⴰⴳⴷⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵢⵜ ⵜⴰⵖⴻⵔⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵢⵜ ⵜⴰⵖⴻⵔⴰⵢⵜ

République Algérienne Démocratique et Populaire

وزارة التعليم العالي والبحث العلمي

ⵎⴰⵎⴻⵔⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵢⵜ ⵜⴰⵖⴻⵔⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵢⵜ

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique



ECOLE NATIONALE
SUPÉRIEURE
D'INFORMATIQUE

المدرسة الوطنية العليا للإعلام الآلي

ⵎⴰⵎⴻⵔⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵢⵜ ⵜⴰⵖⴻⵔⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵢⵜ

École nationale Supérieure d'Informatique

Rapport de TP

Analyse des Données (ANAD)

2^{ème} année Cycle Supérieur (2CS)

Option : SIQ1

Étude de l'influence des habitudes alimentaires et du mode de vie sur les niveaux d'obésité

Réalisé par :

Nadine BOUSDJIRA
Mohamed El Amine KHERROUBI

Encadré par :

Mme Naima BESSAH

Table des matières

1	Introduction	2
1.1	Objectifs de l'étude	2
2	Données et prétraitement	2
2.1	Structure du jeu de données	2
2.2	Problématique méthodologique	2
3	Fondements méthodologiques de l'ACM	3
3.1	Principe général	3
3.2	Correction de Benzécri	3
3.3	Deux approches pour traiter les variables quantitatives	3
3.3.1	Approche 1 : Catégorisation a priori	3
3.3.2	Approche 2 : Projection a posteriori	3
4	Résultats	4
4.1	Inertie expliquée et dimensionnalité	4
4.2	Interprétation des axes factoriels (Approche 1)	4
4.2.1	Dimension 1 : Prédisposition et caractéristiques corporelles	4
4.2.2	Dimension 2 : Mode de mobilité et âge	4
4.3	Projection des individus (Approche 1)	6
4.4	Corrélations avec variables supplémentaires (Approche 2)	7
4.5	Divergences entre approches et rôle du genre	8
4.5.1	Contributions principales en Approche 2	8
4.5.2	Émergence du facteur Genre	8
4.5.3	Qualité de représentation des individus	8
5	Synthèse et discussion	8
5.1	Facteurs structurants de l'obésité	8
5.1.1	Antécédents familiaux : prédicteur primaire	8
5.1.2	Mode de transport : discriminateur comportemental	8
5.1.3	Genre : effet révélé par l'Approche 2	9
5.1.4	Habitudes alimentaires : modulateurs secondaires	9
5.2	Comparaison méthodologique	9
5.3	Stratégie de dépistage	9
6	Conclusion	9

1 Introduction

L'obésité constitue aujourd'hui l'un des défis majeurs de santé publique mondiale. Comprendre les facteurs associés à cette pathologie nécessite d'analyser simultanément de nombreuses variables liées aux habitudes de vie : modes de transport, comportements alimentaires, caractéristiques démographiques et antécédents familiaux. L'Analyse des Correspondances Multiples (ACM) offre un cadre méthodologique particulièrement adapté pour révéler les structures cachées dans de tels ensembles de données qualitatives.

1.1 Objectifs de l'étude

Cette analyse poursuit deux objectifs :

- Mettre en évidence les facteurs associés aux différents niveaux d'obésité
- Comparer deux stratégies méthodologiques pour traiter les variables quantitatives en ACM

Dépôt GitHub : Tous les résultats détaillés, les scripts et les visualisations sont disponibles dans le dépôt GitHub associé à cette étude : <https://github.com/amine-kherroubi/obesity-analysis>.

2 Données et prétraitement

2.1 Structure du jeu de données

L'étude porte sur 2 111 individus décrits par sept variables explicatives et une variable cible (niveau d'obésité, 0–6). Les données sont extraites du jeu de données *Estimation of Obesity Levels Based on Eating Habits and Physical Condition* (Mendoza Palechor & De la Hoz Manotas, 2019), disponible sur le *UCI Machine Learning Repository*. Le jeu de données original contient 16 variables explicatives et une variable cible. Dans ce travail, seules sept variables explicatives ont été retenues.

TABLE 1 – Description des variables

Variable	Description	Modalités / Statistiques
<i>Variables qualitatives</i>		
Gender	Sexe	Male (50.6%), Female (49.4%)
family_history	Antécédents familiaux	yes (81.8%), no (18.2%)
FAVC	Aliments hypercaloriques	yes (88.4%), no (11.6%)
CAEC	Fréquence grignotage	Sometimes (83.6%), Frequently (11.5%), Always (2.5%), no (2.4%)
MTRANS	Mode de transport	Public_Transportation (74.8%), Automobile (21.6%), Walking (2.7%), Motorbike (0.5%), Bike (0.3%)
<i>Variables quantitatives</i>		
Age	Âge (années)	Moyenne = 24.31 (min : 14, max : 61)
Weight	Poids (kg)	Moyenne = 86.59 (min : 39, max : 173)
<i>Variable cible</i>		
NObeyesdad	Niveau d'obésité ; variable cible ; non utilisée dans l'ACM	7 Niveaux (0-6)

2.2 Problématique méthodologique

L'ACM, par construction, traite des variables qualitatives. Se pose alors une question méthodologique centrale : comment intégrer les variables quantitatives Age et Weight ? Deux stratégies sont possibles : la **catégorisation a priori** et la **projection a posteriori**.

3 Fondements méthodologiques de l'ACM

3.1 Principe général

L'ACM généralise l'AFC au cas de plusieurs variables qualitatives. Son principe repose sur la transformation des données en un Tableau Disjonctif Complet (TDC). L'ACM applique ensuite une ACP au TDC, générant des axes factoriels qui maximisent l'inertie expliquée. Les individus et modalités sont projetés dans cet espace réduit, révélant leurs proximités.

3.2 Correction de Benzécri

Le codage disjonctif induit mécaniquement des valeurs propres faibles. Benzécri (1979) propose une correction pour les valeurs propres significatives ($\lambda_k > 1/p$) :

$$\tilde{\lambda}_k = \left[\frac{p}{p-1} \left(\sqrt{\lambda_k} - \frac{1}{p} \right) \right]^2.$$

3.3 Deux approches pour traiter les variables quantitatives

3.3.1 Approche 1 : Catégorisation a priori

Cette stratégie consiste à discrétiser Age et Weight *avant* l'ACM, les transformant en variables qualitatives à part entière. Les catégories deviennent des modalités actives qui contribuent à la construction des axes factoriels.

Discrétisation retenue :

- Age_Cat : _Young (≤ 25 ans, 64.8%), _Adult (26-40 ans, 32.4%), _Senior (> 40 ans, 2.7%)
- Weight_Cat : _Light (< 65 kg, 24.6%), _Medium (65-85kg, 28.8%), _Heavy (> 85 kg, 46.6%)

Le TDC comporte alors 21 modalités issues de 7 variables qualitatives.

Avantages : Les variables Age et Weight influencent directement les axes, permettant d'identifier des profils d'âge ou de poids spécifiques. Les modalités catégorisées contribuent au calcul de l'inertie.

Limites : Le choix des seuils est arbitraire ; la discrétisation entraîne une perte d'information.

3.3.2 Approche 2 : Projection a posteriori

Cette stratégie effectue l'ACM uniquement sur les 5 variables qualitatives (15 modalités). Age et Weight sont ensuite projetés comme variables supplémentaires via le calcul de leurs corrélations avec les composantes principales.

Projection : Pour une variable quantitative X , sa corrélation avec la dimension k est :

$$r(X, Dim_k) = \frac{\text{cov}(X, Dim_k)}{\sigma_X \cdot \sigma_{Dim_k}}$$

Avantages : Aucune perte d'information (variables continues conservées) ; indépendance vis-à-vis des choix de discrétisation ; identification des corrélations continues Age/Weight avec les dimensions.

Limites : Age et Weight n'influencent pas la construction des axes ; leur effet est observé *ex post* uniquement.

Choix interprétatif : Les deux approches seront utilisées conjointement afin de comparer leurs résultats et d'analyser les différences induites par la discrétisation des variables quantitatives par rapport à leur projection comme variables supplémentaires.

4 Résultats

4.1 Inertie expliquée et dimensionnalité

TABLE 2 – Taux d’inertie corrigés (Benzécri) pour les deux approches

Dimension	Approche 1		Approche 2	
	% variance	% cumul	% variance	% cumul
1	25.73%	25.73%	23.23%	23.23%
2	14.76%	40.48%	15.62%	38.86%
3	11.47%	51.95%	12.06%	50.91%
4	9.80%	61.75%	10.77%	61.68%
5	8.68%	70.44%	8.52%	70.20%

Les deux premières dimensions capturent environ 40% de l’inertie totale (40.48% et 38.86% respectivement). Pour atteindre environ 70% de variance totale, il faudrait considérer les cinq premières dimensions. Néanmoins, pour des raisons de visualisation, nous nous limitons à une représentation en deux dimensions.




FIGURE 1 – Décroissance des valeurs propres (Approche 1)

4.2 Interprétation des axes factoriels (Approche 1)

4.2.1 Dimension 1 : Prédilection et caractéristiques corporelles

D’après la Figure 3, Dim1 représente un gradient de prédilection génétique et de statut pondéral. Les contributeurs majeurs sont `family_history` (33.6%), `Weight_Cat_Light/Heavy` (32.3%/31.2%), `CAEC_Sometimes` (30.7%) et `Age_Cat_Young` (29.7%). Ces modalités opposent individus légers sans antécédents (gauche) à individus lourds avec antécédents familiaux (droite). La Figure 4 révèle qu’aucune modalité n’atteint individuellement un $\cos^2$ supérieur à 0.5 sur Dim1 seule. Les modalités de poids et d’antécédents familiaux atteignent néanmoins des valeurs de $\cos^2$ notables (0.3-0.4), confirmant leur rôle structurant sur cet axe.

4.2.2 Dimension 2 : Mode de mobilité et âge

Comme l’illustre la Figure 3, Dim2 structure l’opposition transports publics (haut) versus automobile (bas), capturant un pattern générationnel. Les contributeurs dominants sont `MTRANS_Public_Trans` (52.5%), `MTRANS_Automobile` (47.2%), et `Age_Cat_Young/Adult` (31.7%/25.2%). La Figure 4 révèle que les modalités MTRANS affichent une très bonne qualité de représentation : `MTRANS_Public_Trans` atteint un $\cos^2$ de 0.709 sur Dim2 seule et 0.767 sur Dim1+Dim2, tandis que `MTRANS_Automobile` atteint 0.626 et 0.728 respectivement. Ces valeurs élevées ($\cos^2 > 0.7$ sur Dim1+Dim2) confirment que

ces modalités sont excellentement représentées dans le plan factoriel. En revanche, les modalités rares (Bike, Motorbike) présentent des $\cos^2$ très faibles (non visibles sur la figure).




FIGURE 2 – Cercle des corrélations des modalités avec Dim1 et Dim2 (Approche 1)




FIGURE 3 – Contributions des modalités aux axes Dim1 et Dim2 (Approche 1)




FIGURE 4 – Qualités de représentation des modalités sur Dim1 et Dim1+Dim2 (Approche 1)

4.3 Projection des individus (Approche 1)

La figure 5 révèle une dispersion modérée avec chevauchement substantiel entre niveaux d'obésité, confirmant la nature multifactorielle du phénomène et la non suffisance de deux dimensions. Néanmoins, une tendance apparaît : les niveaux faibles se concentrent dans le quadrant inférieur-gauche (jeunes, légers, transports publics), tandis que les niveaux élevés se dispersent avec une légère tendance vers la droite (adultes, lourds, antécédents familiaux).




FIGURE 5 – Projection des individus colorés par niveau d'obésité (Approche 1)

La figure 6 indique que 18.3% des individus sont bien représentés ($\cos^2 > 0.7$), 36.7% modérément ($0.4-0.7$) et 45.0% faiblement (≤ 0.4). Cette hétérogénéité suggère que certains profils ne s'inscrivent pas dans les deux dimensions principales.




FIGURE 6 – Qualités de représentation des individus (Approche 1)

4.4 Corrélations avec variables supplémentaires (Approche 2)

Par souci de concision, tous les résultats de l'Approche 2 sont gardés dans le [dépôt GitHub](#).




FIGURE 7 – Cercle de corrélations avec projection de Age et Weight (Approche 2)

En Approche 2, Age et Weight sont projetés a posteriori (Figure 7). D'après la visualisation :

- Weight $\leftrightarrow$ Dim1 : $r = +0.550$ — forte corrélation positive
- Age $\leftrightarrow$ Dim1 : $r = +0.299$ — corrélation modérée positive
- Age $\leftrightarrow$ Dim2 : $r = -0.296$ — corrélation modérée négative
- Weight $\leftrightarrow$ Dim2 : $r = +0.129$ — faible corrélation positive

Le signe positif de $r(\text{Weight}, \text{Dim1})$ confirme que les poids élevés sont associés à la partie positive de Dim1, là où se situent `family_history_yes` et les comportements à risque (`FAVC_yes`, `CAEC_Sometimes`). `Weight` apparaît comme le prédicteur quantitatif dominant, corroborant les résultats de l'Approche 1. `Age` contribue modérément aux deux dimensions, reflétant des effets générationnels : les jeunes (âge faible) sont associés aux transports publics (Dim2 positive), tandis que les adultes (âge élevé) sont associés à l'automobile (Dim2 négative).

4.5 Divergences entre approches et rôle du genre

4.5.1 Contributions principales en Approche 2

Dimension 1 :

- `family_history_yes/no` : 41.5% (encore plus dominant)
- `CAEC_Sometimes` : 39.3%; `CAEC_Frequently` : 34.3%
- `FAVC_yes/no` : 32.7%

Dimension 2 :

- `MTRANS_Public_Transportation` : 47.4%
- `Gender_Male/Female` : 45.5% — émergence remarquable
- `MTRANS_Automobile` : 38.7%

4.5.2 Émergence du facteur Genre

En l'absence de `Age_Cat` et `Weight_Cat`, la variable `Gender` contribue significativement à Dim2 (45.5% contre 20.1% en Approche 1). Cela révèle que le genre interagit structurellement avec les choix de transport, mais cet effet était partiellement masqué par la catégorisation de l'âge en Approche 1. Cette observation suggère des patterns genrés dans la mobilité quotidienne, potentiellement liés à des différences socio-professionnelles.

4.5.3 Qualité de représentation des individus

L'Approche 2 présente une meilleure qualité globale de représentation des individus : 37.8% sont bien représentés ($\cos^2 > 0.7$) contre 18.3% en Approche 1. Le $\cos^2$ moyen passe de 0.448 (Approche 1) à 0.521 (Approche 2), suggérant que l'absence de catégorisation permet une structure plus nette dans l'espace factoriel. Toutefois, la proportion d'individus faiblement représentés augmente également (56.3% contre 45.0%), indiquant une polarisation accrue : certains individus sont mieux projetés, d'autres moins bien.

5 Synthèse et discussion

5.1 Facteurs structurants de l'obésité

5.1.1 Antécédents familiaux : prédicteur primaire

Les deux approches convergent pour identifier `family_history_with_overweight` comme le facteur le plus structurant (contributions 33.6% à 41.5% sur Dim1). Cette prédominance souligne l'importance de la composante héréditaire dans l'obésité, qu'elle soit génétique ou liée à des habitudes familiales transmises. Les antécédents familiaux structurent l'axe principal indépendamment de la méthodologie adoptée.

5.1.2 Mode de transport : discriminateur comportemental

Le mode de transport domine systématiquement Dim2 (contributions 47-52%), opposant clairement transports publics et automobile. Cette dichotomie reflète des différences d'activité physique quotidienne mais aussi des patterns socio-économiques et générationnels. La qualité de représentation exceptionnelle ($\cos^2 > 0.7$ sur Dim1+Dim2) des modalités principales valide cette interprétation.

5.1.3 Genre : effet révélé par l'Approche 2

L'Approche 2 met en lumière un effet du genre (contribution 45.5% sur Dim2), initialement moins apparent en Approche 1 (20.1%). Cette émergence indique que le genre et transport sont liés structurellement.

5.1.4 Habitudes alimentaires : modulateurs secondaires

FAVC et CAEC contribuent modérément (22-39%), confirmant leur rôle dans l'obésité mais de manière moins structurante qu'attendu. Ces variables semblent agir comme modulateurs plutôt que comme déterminants primaires.

5.2 Comparaison méthodologique

TABLE 3 – Synthèse comparative des deux approches

Critère	Approche 1	Approche 2
Variance Dim1+2	40.48%	38.86%
Nombre de modalités	21 (7 variables)	15 (5 variables)
Contributeurs Dim1	family_history + Weight_Cat	family_history + CAEC
Contributeurs Dim2	MTRANS + Age_Cat	MTRANS + Gender
Cos ² moyen individus	0.448	0.521

Recommandation : Privilégier l'Approche 2 pour l'interprétation principale (structure factorielle plus nette, révélation de l'effet du genre, meilleure qualité individuelle moyenne). Utiliser l'Approche 1 pour identifier des seuils critiques Age/Weight et valider la robustesse des conclusions.

5.3 Stratégie de dépistage

L'ACM suggère un questionnaire de dépistage simple et efficace :

1. Antécédents familiaux de surpoids ? (prédicteur primaire)
2. Mode de déplacement quotidien ? (indicateur comportemental)
3. Consommation régulière d'aliments hypercaloriques ? (modulateur)

6 Conclusion

Cette analyse révèle que l'obésité résulte d'une interaction complexe entre prédisposition (antécédents familiaux, poids), comportements (transport, alimentation) et facteurs démographiques (âge, genre).

La comparaison de deux approches méthodologiques — catégorisation a priori versus projection a posteriori — révèle des nuances : l'Approche 2 offre une meilleure qualité de représentation moyenne et dévoile l'effet du genre, tandis que l'Approche 1 permet d'identifier des seuils critiques et révèle mieux l'association entre poids catégorisé et prédisposition. La nécessité de cinq dimensions pour atteindre 70% de variance confirme la nature multifactorielle de l'obésité.

Références

- Cours ANAD 2CS SIQ_SIL, N. Bessah, 8 novembre 2025
- Mendoza Palechor, F., & De la Hoz Manotas, A. (2019). *Estimation of Obesity Levels Based On Eating Habits and Physical Condition [Dataset]*. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5H31Z>